

Attention contextuelle Write–Read–Value : étude d’un chemin architectural

Anonymous authors

Paper under double-blind review

Abstract

Nous étudions une attention contextuelle Write–Read–Value (W/R/V) dans des modèles de langage causaux d’environ 98,2 millions de paramètres. W/R/V emploie huit têtes de lecture contextuelles, deux têtes partagées d’écriture/valeur, une normalisation RMS par tête, RoPE et un softmax causal via PyTorch SDPA. Dans une comparaison contrôlée sur H200, GQA et W/R/V partagent tokenizer, flux FineWeb-Edu, budget de 100 007 936 tokens, optimiseur, learning rate maximal, mode BF16, protocole d’évaluation et trois seeds. W/R/V améliore la loss tenue à part sur les trois paires : moyenne $4,684432 \pm 0,021137$ contre $4,703035 \pm 0,017657$ pour GQA, avec un écart apparié moyen de $-0,018604$. Le débit moyen est de 121 448 contre 125 021 tokens/s, soit une pénalité de 2,86%. Avec seulement trois paires, l’intervalle t à 95% de l’écart moyen, $[-0,0541; 0,0169]$, contient zéro ; nous rapportons donc une observation cohérente à petite échelle, non une supériorité universelle. Les anciens runs WVR à état fixe et à écriture lexicale ne servent que de chemin architectural historique. La condition W/R/V contrôlée désactive le résidu lexical d’écriture.

1 Introduction

Les modèles de langage fondés sur l’attention combinent transport contextuel et sélection dépendante du contenu parmi les représentations individuelles des tokens passés. Nous étudions une paramétrisation contextuelle groupée Write–Read–Value (W/R/V) et son compromis qualité–débit face à GQA sous un budget apparié.

Chaque token traverse le même chemin dense. Le mélangeur principal est une attention causale W/R/V à huit têtes de lecture contextuelles et deux têtes partagées d’écriture/valeur. RMSNorm par tête et RoPE précèdent PyTorch SDPA. W/R/V et GQA conservent les mêmes branches feed-forward d’objets lexicaux et de micro-experts déterministes ; les runs W/R/V contrôlés désactivent le résidu lexical d’écriture séparé.

Cette architecture provient d’une étude systématique de WVR à état fixe. Ces variantes sont compatibles avec une limitation d’une matrice comprimée unique pour la sélection d’occurrences. Nous les conservons comme ablations de chemin négatives plutôt que comme architecture finale.

Nos contributions sont empiriques :

- une attention contextuelle W/R/V avec têtes de lecture/écriture groupées, normalisation RMS par tête, RoPE et SDPA configuré pour autoriser FlashAttention ;
- une comparaison H200 contrôlée à trois seeds contre GQA, à 100 007 936 tokens par run ;
- une loss moyenne W/R/V de 4,684432 contre 4,703035 pour GQA, W/R/V étant inférieur sur les trois seeds avec 2,86% de débit en moins ;
- des ablations de chemin qui motivent, sans les isoler, des hypothèses sur l’adressage comprimé ou lexical ;
- un rapport fondé sur les artefacts bruts qui sépare observations terminées et revendications architecturales appariées en optimisation.

Le résultat apparié est cohérent mais faible : avec trois seeds, son intervalle à 95% contient zéro. Nous ne revendiquons donc ni significativité statistique ni supériorité universelle. La contribution est une observation appariée entièrement archivée et un chemin exécutable à tester à plus grande échelle.

2 Méthode

2.1 Attention contextuelle W/R/V

Soit $\mathbf{H} \in \mathbb{R}^{B \times T \times d}$ le tenseur des états cachés normalisés. Chaque couche projette des lectures, écritures et valeurs contextuelles,

$$\mathbf{R} = \mathbf{H}\mathbf{W}_r, \quad \mathbf{W}_{\text{ctx}} = \mathbf{H}\mathbf{W}_w, \quad \mathbf{V} = \mathbf{H}\mathbf{W}_v. \quad (1)$$

Le modèle évalué utilise huit têtes de lecture et deux têtes partagées d’écriture/valeur, de dimension 48. Lectures et écritures reçoivent des normalisations RMS indépendantes par tête et un encodage rotatif. Les têtes W/V sont répétées par groupes de quatre têtes R, puis l’attention causale est

$$\mathbf{y}_{t,h} = \sum_{j \leq t} \text{softmax}_j \left(\frac{\text{RoPE}(\mathbf{r}_{t,h})^\top \text{RoPE}(\mathbf{w}_{j,\kappa(h)})}{\sqrt{48}} \right) \mathbf{v}_{j,\kappa(h)}. \quad (2)$$

PyTorch SDPA est configuré pour autoriser le dispatch FlashAttention sur H200. W/R/V est donc bien un mécanisme d’attention : R et W occupent respectivement la frontière technique query/key de SDPA, tandis que V reste contextuel. La terminologie décrit le flux, non un opérateur sans attention. En décodage incrémental, les tenseurs W et V passés sont conservés et croissent avec le préfixe. Un résidu lexical d’écriture exploratoire existe dans l’implémentation, mais il est fixé à zéro et omis dans tous les runs contrôlés du tableau 1.

2.2 Objet lexical résiduel partagé

La transformation feed-forward partagée est un SwiGLU dense,

$$\mathbf{F}(\mathbf{h}) = \mathbf{W}_d [\text{SiLU}(\mathbf{W}_g \mathbf{h}) \odot \mathbf{W}_u \mathbf{h}]. \quad (3)$$

Pour l’identité de token x_t , une table partagée $\mathbf{E} \in \mathbb{R}^{|\mathcal{V}| \times r}$ fournit une modulation de faible rang :

$$\mathbf{z}_t = \text{SiLU}(\mathbf{U}\mathbf{h}_t) \odot (\mathbf{1} + \mathbf{E}[x_t]), \quad (4)$$

$$\mathbf{O}(\mathbf{h}_t, x_t) = \mathbf{D}\mathbf{z}_t. \quad (5)$$

La même table $\mathbf{E}$ est partagée entre les couches ; les matrices de projection restent propres à chaque couche. Mettre $\mathbf{E}$ à zéro neutralise initialement la modulation dépendante du token, mais la branche objet reste active via une porte non nulle α :

$$\mathbf{F}_{\text{objet}}(\mathbf{h}_t, x_t) = \mathbf{F}(\mathbf{h}_t) + \alpha \mathbf{O}(\mathbf{h}_t, x_t). \quad (6)$$

2.3 Résidu de micro-expert déterministe

Chaque couche affecte le token x_t à l’un des N micro-experts selon

$$e_\ell(x_t) = (x_t + \ell) \bmod N. \quad (7)$$

Toutes les activations cachées expertes sont calculées dans une même opération tensorielle régulière, puis la sortie retenue est sélectionnée sans tri ni dispersion. Pour une largeur experte w ,

$$\mathbf{R}_\ell(\mathbf{h}_t, x_t) = \beta \mathbf{W}_d^{(e_\ell(x_t))} \left[\text{SiLU}(\mathbf{W}_g^{(e_\ell(x_t))} \mathbf{h}_t) \odot \mathbf{W}_u^{(e_\ell(x_t))} \mathbf{h}_t \right]. \quad (8)$$

La sortie feed-forward complète est $\mathbf{F} + \alpha \mathbf{O} + \beta \mathbf{R}$. Il s’agit d’un résidu lexical ajouté à un chemin dense partagé, et non d’une affirmation selon laquelle le routage remplacerait le calcul commun.

2.4 Ablation associative WVR à état fixe

L’ablation antérieure à état fixe utilise une matrice associative récurrente plutôt qu’une attention softmax. Nous appelons ce mécanisme *WVR* : adresse d’écriture (Write), valeur contextualisée (Value) et adresse de lecture (Read). Pour le token x_t et l’état caché $\mathbf{h}_t$, une forge lexicale compressée réutilise la table d’objets lexicaux liée,

$$\mathbf{f}_t = \mathbf{W}_{f,2} \text{SiLU}(\mathbf{W}_{f,1} \mathbf{E}[x_t]), \quad (9)$$

avec un goulot implémenté $16 \rightarrow 4 \rightarrow 128$. L’adresse commune combine ce code lexical déterministe avec une signature projetée de l’état caché,

$$\mathbf{c}_t = \text{norm}(\mathbf{W}_c \mathbf{h}_t), \quad (10)$$

$$\mathbf{a}_t = \text{norm}(\text{forge}(x_t) + \tanh(\eta) \mathbf{c}_t). \quad (11)$$

Le code lexical est une adresse liée à l’identité du token ; il ne constitue pas une preuve de représentation sémantique. La projection contextuelle est elle aussi décrite opérationnellement, sans revendication sémantique.

L’écriture emploie l’adresse précédente et la valeur cachée contextualisée courante,

$$\mathbf{w}_t = \mathbf{a}_{t-1}, \quad \mathbf{v}_t = \mathbf{W}_v \mathbf{h}_t, \quad \mathbf{r}_t = \mathbf{a}_t, \quad (12)$$

$$\hat{\mathbf{v}}_t = \mathbf{w}_t^\top \mathbf{M}_{t-1}, \quad (13)$$

$$\mathbf{M}_t = \lambda \mathbf{M}_{t-1} + \rho \mathbf{w}_t (\mathbf{v}_t - \hat{\mathbf{v}}_t)^\top, \quad (14)$$

$$\mathbf{y}_t = \mathbf{r}_t^\top \mathbf{M}_{t-1}, \quad (15)$$

$$\mathbf{c}_t^{\text{WVR}} = \gamma \mathbf{W}_o \mathbf{y}_t. \quad (16)$$

Le résidu de contexte $\mathbf{c}_t^{\text{WVR}}$ est ajouté à la sortie de la convolution causale. L’implémentation décale causalement le flux d’écriture : la lecture courante utilise $\mathbf{r}_t$, tandis que l’adresse d’écriture précédente est appariée au payload courant. La résolution triangulaire par segments constitue une parallélisation exacte de cette récurrence. WVR mémorise donc une valeur cachée contextualisée, et non un code lexical. L’état comprend une matrice de rang 128 ainsi que des vecteurs d’adresse et de charge de taille fixe, indépendamment de la longueur du préfixe.

La normalisation des collisions maintient une estimation diagonale amortie de charge $\mathbf{d}_t$ et redimensionne les coordonnées de lecture et d’écriture par $(\mathbf{d}_t + \epsilon)^{-1/2}$ avant normalisation. Elle ne partitionne pas la matrice de rang 128 en plusieurs mémoires.

L’attention QKV compare une requête contextualisée à chaque clé conservée et réalise une compétition normalisée entre occurrences individuelles. WVR lit au contraire l’association récurrente pré-mise-à-jour par $\mathbf{r}_t^\top \mathbf{M}_{t-1}$. Notre comparaison porte sur la qualité et le débit, sans crédit lié à la taille d’un KV cache. WVR possède un état fixe, mais des occurrences répétées ou en collision peuvent s’écraser.

L’extension expérimentale d’adresse d’occurrence remplace la projection contextuelle dense par une signature compacte $d \rightarrow 8 \rightarrow 128$ et ajoute une signature positionnelle déterministe contrôlée,

$$\mathbf{a}_t = \text{norm}(\text{forge}(x_t) + \text{smallextx}(\mathbf{h}_t) + \tanh(\gamma) \text{pos}(t)), \quad (17)$$

avec $\gamma = 0$ à l’initialisation et un unique compteur de position de taille fixe pour le décodage incrémental. Son entraînement terminé au budget complet est rapporté comme ablation négative.

2.5 Ablations du chemin architectural

Nous conservons trois conditions intermédiaires terminées : une couche W/R/V insérée dans le modèle WVR à collisions, huit couches aux adresses fortement lexicales, puis huit couches contextuelles avec deux couches WVR restantes. Ce sont des ablations de chemin, non des contrôles factoriels isolés ; leur ordre motive des hypothèses sans en identifier les causes.

3 Protocole expérimental

3.1 Comparaison contrôlée

L'expérience principale compare GQA dense à l'attention contextuelle W/R/V. Les deux modèles ont dix couches, une dimension cachée de 384, huit têtes de lecture/query, deux têtes partagées d'écriture/valeur ou key/value, et le même chemin feed-forward à objets lexicaux et micro-experts. GQA compte 98 179 844 paramètres et W/R/V 98 195 204 (écart de 0,016%). Le résidu lexical d'écriture W/R/V est fixé à zéro et omis, tandis que RMSNorm par tête sur R et W reste active.

3.2 Données, tokenizer et budget

Les six runs utilisent le tokenizer `o200k_base` de 200 019 entrées et FineWeb-Edu `sample-10BT`, des séquences de 2 048, BF16, un batch de 16 et les seeds 42–44. Chaque run effectue 3 052 étapes, soit exactement 100 007 936 tokens. Un flux déterministe de 5% des documents est réservé à l'évaluation. L'estimation finale moyenne 32 batches (1 048 576 tokens) à l'étape 3 000. Le shard archivé est fixé à la révision 87f0914, SHA-256 b1ba7b2c...d78e871.

Les deux conditions utilisent AdamW, un LR maximal de 4×10^{-4} , weight decay 0,1, le même warmup/decay, une loss exacte sur le vocabulaire par chunks, l'exécution eager et la même pile H200. La compilation est désactivée pour les deux, car le chemin à table lexicale liée produisait des gradients non finis avec la pile compilateur testée; eager restait fini.

3.3 Mesures et débit

Nous séparons entropie croisée next-token et débit d'entraînement. Pour chaque run, le débit est la médiane des points finis après l'étape 500, en excluant les points sous 80k tokens/s dus aux évaluations, checkpoints ou pauses réseau. Nous rapportons la moyenne des trois médianes. L'écart apparié est W/R/V moins GQA à seed identique. Avec $n = 3$, nous donnons l'écart-type échantillonnal et un intervalle t bilatéral à 95%, sans l'interpréter comme preuve de significativité.

3.4 Preuves archivées

Chaque run possède une configuration JSON réalisée, un CSV par étape, un checkpoint final, un commit source et un manifeste SHA-256. Le shard Parquet FineWeb-Edu exact de 2,15 Go est archivé pour réévaluation offline. Les anciens runs H100 WVR/W/R/V n'emploient pas le même protocole et ne servent que de chemin descriptif.

3.5 Matériel et vérifications numériques

Les runs contrôlés utilisent un NVIDIA H200 avec PyTorch SDPA autorisant FlashAttention. Les tests FP32 couvrent causalité, padding, formes groupées, RoPE, cache, équivalence de la projection R/W/V fusionnée, invariance lexical-off et équivalence full/incrémental. Le cache W/V croît avec le préfixe, comme un cache KV groupé; W/R/V n'est présenté ni comme état fixe ni comme sans attention.

4 Résultats

4.1 Comparaison H200 contrôlée

W/R/V obtient une loss inférieure sur les trois seeds. L'écart apparié moyen est $-0,018604$, environ 0,40% de la moyenne GQA. L'intervalle t bilatéral à 95% est $[-0,0541; 0,0169]$. Comme il contient zéro et ne porte que sur trois paires, nous décrivons un ordre cohérent dans cette expérience, non un résultat statistiquement établi.

W/R/V est plus lent de 3 573 tokens/s en moyenne, soit une pénalité de 2,86%. Qualité et débit évoluent donc en sens opposé : il ne s'agit pas d'une amélioration de Pareto.

TABLE 1 – Loss tenue à part appariée par seed. Chaque valeur est l’évaluation finale à l’étape 3 000 sur 1 048 576 tokens.

Seed	GQA	W/R/V	W/R/V – GQA
42	4,683425	4,662531	−0,020894
43	4,717673	4,686053	−0,031620
44	4,708008	4,704711	−0,003297
Moyenne	4,703035	4,684432	−0,018604
Écart-type	0,017657	0,021137	0,014300

TABLE 2 – Débit d’entraînement sur un H200. Chaque seed contribue sa médiane après warmup et exclusion des pauses d’évaluation/checkpoint ; moyenne et écart-type sont calculés entre seeds.

Mécanisme	Débit moyen ↑	Écart-type
GQA	125 021	100
W/R/V contextuel	121 448	254

4.2 Chemin architectural historique

Les anciens runs H100 à une seed ont motivé la comparaison sans lui être appariés. Leurs losses clés sont 4,895427 pour WVR à collisions normalisées, 4,892026 après ajout d’une couche W/R/V, 4,973798 pour huit couches fortement lexicales, 4,852761 pour l’hybride contextuel huit couches et 4,706118 pour dix couches contextuelles avec RMSNorm. Ils documentent uniquement le développement ; aucune causalité ne leur est attribuée.

Les proxies courts ont filtré les échecs sans classer fiablement les modèles : plusieurs résultats favorables de forge lexicale ou multi-échelles n’ont pas progressé au budget complet. Le modèle contrôlé retire donc le résidu lexical d’écriture du chemin d’attention W/R/V. Les objets lexicaux et micro-experts feed-forward restent identiques entre GQA et W/R/V.

Deux ablations H200 à la seed 42 sont rapportées descriptivement sans être agrégées à la comparaison sur trois seeds. Activer le résidu lexical d’écriture donne une loss de 4,660939 contre 4,662531 lorsqu’il est désactivé, soit −0,001592, tout en réduisant le débit médian de 121 479 à 119 121 tokens/s (−1,94%). Désactiver RMSNorm par tête sur R/W donne une loss de 4,795811, soit +0,133280 par rapport à la condition normalisée lexical-off, à 123 257 tokens/s. Le run avec résidu lexical utilise un commit source antérieur et les deux comparaisons n’ont qu’une seed ; elles motivent des ablations appariées sans isoler d’effet causal.

4.3 Contrôles négatifs à état fixe

Les expériences historiques à état fixe restent des contrôles négatifs. Le run convolutionnel séparé à un milliard de tokens ne peut être classé avec les conditions à 100M. Les sondes archivées de rappel associatif et d’induction donnent zéro pour les checkpoints sans attention, mais l’artefact GQA ne documente pas un protocole identique ; aucune comparaison positive quantitative n’est revendiquée.

Les tests FP32 reproduisent W/R/V full en incrémental token par token à une tolérance de 10^{-5} . Les tenseurs W/V retenus croissent avec le contexte : cela vérifie l’implémentation causale, non un service à état fixe.

5 Travaux connexes

Les Transformers utilisent une compétition contextuelle query-key et une agrégation de valeurs (Vaswani et al., 2017). GQA partage les têtes key/value entre groupes de queries afin de réduire mémoire et bande passante (Ainslie et al., 2023). L’opération centrale W/R/V appartient à cette famille : les lectures jouent le rôle des queries, les écritures partagées celui des keys, et les valeurs restent contextuelles. Nous ne prétendons

donc pas qu’un changement de vocabulaire crée un nouvel opérateur. Nous évaluons la paramétrisation R/W/V réalisée et ses choix de normalisation sous un protocole apparié.

Le modèle final emploie aussi des composants établis : RoPE (Su et al., 2021), une normalisation par tête de R/W proche de query-key normalization (Henry et al., 2020), et des kernels d’attention exacte sensibles aux entrées/sorties (Dao et al., 2022). La question empirique porte sur cette combinaison concrète sous un budget de petit modèle.

RWKV, RetNet et Mamba développent des alternatives récurrentes ou à espace d’état au traitement linéaire de séquence (Peng et al., 2023; Sun et al., 2023; Gu & Dao, 2023). Nos ablations WVR à état fixe leur sont plus proches par motivation que le modèle W/R/V final, mais utilisent une matrice associative unique distincte et sont moins performantes dans nos contrôles. Le modèle final abandonne l’état fixe et conserve des caches W/V groupés ; il ne doit pas être présenté comme concurrent à état linéaire de ces méthodes.

6 Limites et impact élargi

Les preuves contrôlées se limitent à environ 98,2M paramètres, un tokenizer, un shard FineWeb-Edu, 100M tokens et trois seeds. L’ordre est cohérent, mais l’intervalle à 95% contient zéro. Il n’établit ni significativité, ni comportement à l’échelle, ni gain downstream, ni supériorité universelle sur GQA.

La comparaison modifie un ensemble : paramétrisation R/W/V et RMSNorm par tête sur R/W. Les six runs n’isolent pas factoriellement la normalisation. Les observations exploratoires à une seed avec écriture lexicale et sans normalisation sont exclues du tableau contrôlé parce qu’elles ne constituent pas des comparaisons appariées sur trois seeds. Des contrôles appariés supplémentaires sont requis avant d’attribuer le gain à un composant.

Le débit dépend de l’implémentation, du logiciel et du H200. Eager est utilisé car la pile compilateur testée produisait des gradients non finis dans un chemin à table lexicale partagée. La pénalité de 2,86% n’est pas une estimation d’inférence en production. Le cache W/V croît avec le contexte. Prefill long, premier token, distributions de latence, bande passante mémoire et CUDA Graph restent hors portée.

FineWeb-Edu hérite des limites des corpus web : provenance incertaine, déséquilibres et contenus nocifs possibles. L’architecture ne les supprime pas. Le shard est archivé pour reproductibilité exacte et doit être géré selon la licence et la gouvernance de sa source.

Enfin, ce travail est une étude de chemin, non la revendication d’un nouvel opérateur softmax. R et W occupent la frontière technique query/key de SDPA. La terminologie explicite le flux de données ; renommer Q/K/V ne constitue pas seul une contribution algorithmique.

7 Conclusion

Nous évaluons W/R/V contextuel avec huit têtes de lecture, deux têtes partagées d’écriture/valeur, RMSNorm par tête sur R/W, RoPE et SDPA causal. Sur six runs H200 appariés, W/R/V obtient une loss inférieure à GQA sur les trois seeds : $4,684432 \pm 0,021137$ contre $4,703035 \pm 0,017657$. Son débit moyen est de 121 448 contre 125 021 tokens/s, soit une pénalité de 2,86%.

Le résultat est encourageant mais étroit. Trois paires n’établissent pas la significativité, l’intervalle à 95% contient zéro, et l’expérience n’isole pas RMSNorm de la paramétrisation globale. La contribution est une comparaison complète fondée sur les artefacts—configs, CSV, checkpoints, commits, shard et checksums—qui transforme un chemin historique en hypothèse reproductible pour une évaluation à plus grande échelle.

Références

- Joshua Ainslie, James Lee-Thorp, Michiel de Jong, Yury Zemlyanskiy, Federico Lebrón, and Sumit Sanghai. Gqa : Training generalized multi-query transformer models from multi-head checkpoints. 2023.
- Tri Dao, Daniel Y. Fu, Stefano Ermon, Atri Rudra, and Christopher Ré. Flashattention : Fast and memory-efficient exact attention with io-awareness. 2022.

- Albert Gu and Tri Dao. Mamba : Linear-time sequence modeling with selective state spaces. 2023.
- Alex Henry, Prudhvi Raj Dachapally, Shubham Pawar, and Yuxuan Chen. Query-key normalization for transformers. 2020.
- Bo Peng et al. Rwkv : Reinventing rnns for the transformer era. 2023.
- Jianlin Su, Yu Lu, Shengfeng Pan, Ahmed Murtadha, Bo Wen, and Yunfeng Liu. Roformer : Enhanced transformer with rotary position embedding. 2021.
- Yutao Sun et al. Retentive network : A successor to transformer for large language models. 2023.
- Ashish Vaswani et al. Attention is all you need. 2017.

A Liste de contrôle pour la reproductibilité

Le package anonyme contient :

- un mini-framework autonome implémentant W/R/V contextuel, GQA apparié, le chemin feed-forward partagé à objets lexicaux/micro-experts, l’entraînement, l’évaluation et les tests ciblés, sans dépendance au framework de recherche des auteurs ;
- les configurations JSON réalisées et CSV par étape pour les seeds 42–44, plus les deux ablations exploratoires à la seed 42 ;
- paramètres, budgets, optimiseur, mode numérique, backend et commits source ;
- la révision, le chemin et le SHA-256 du shard FineWeb-Edu ;
- un résumé lisible par machine dont dérivent les tableaux 1 et 2 ;
- les tests de causalité, formes groupées, RoPE, lexical-off, projection fusionnée et cache full/incrémental.

Le shard est `sample/10BT/000_00000.parquet`, révision `87f09149ef4734204d70ed1d046ddc9ca3f2b8f9`, SHA-256 `b1ba7b2ce4cb5ea6ef42dca40263eabb85f37700d01693a68e9b30a31d78e871`. Chaque run traite 32 768 tokens par étape pendant 3 052 étapes ; l’évaluation finale utilise 32 batches déterministes à l’étape 3 000.

Le ZIP exclut historique Git, credentials, adresses cloud, noms d’hôtes, chemins locaux, logs, checkpoints et shard de 2,15 Go. Les checkpoints ne sont pas nécessaires à la comparaison rapportée ; l’identité figée du dataset permet son téléchargement exact. Le ZIP extrait et les métadonnées PDF sont scannés avant soumission.